TRABAJO PRÁCTICO

TECNICATURA UNIVERSITARIA EN GESTIÓN Y ANÁLISIS DE DATOS EN ORGANIZACIONES

¿Qué estadísticas influyen más en la probabilidad de que un equipo gane?

Un análisis de cinco ligas europeas de fútbol entre 2000/01 y 2024/25

Materia	Laboratorio de Métodos Cuantitativos aplicados a la Gestión
Integrantes	Ciraldo Santino Ursino Nicolas
Datos	football-data.co.uk · 5 ligas europeas · 44.957 partidos (2000/01 – 2024/25)
Técnica	Análisis exploratorio y regresión logística
Herramientas	Python (pandas, NumPy, Matplotlib) · Google Colab
Fecha	Noviembre de 2026

1. Resumen

Este trabajo indaga qué estadísticas de un partido se asocian más con la probabilidad de ganar, poniendo a prueba la idea de que “gana el que más tira”. Se analizaron 44.957 partidos de las cinco grandes ligas europeas entre las temporadas 2000/01 y 2024/25 (fuente: football-data.co.uk), de los cuales 37.694 contaban con estadísticas completas. Se combinó un análisis exploratorio con una regresión logística que explica la victoria de un equipo a partir de su diferencia con el rival en tiros, corners, faltas y tarjetas, y de la localía. Los resultados indican que importa menos cuánto se tira que cuánto se tira al arco: un equipo que iguala a su rival en tiros al arco gana el 33,5 % de los partidos, y con dos tiros de ventaja la cifra sube al 50,1 %, mientras que corners y faltas casi no distinguen entre ganar y perder. La localía es el segundo factor, aunque la proporción de victorias locales bajó del 47,9 % al 42,7 % en 25 años. El modelo clasifica correctamente el 74,5 % de los casos. La base no incluye posesión, limitación que se plantea como extensión futura.

2. Introducción

En el fútbol circulan muchas ideas sobre qué hace ganar un partido: que gana el que más tira, que la localía pesa, que quien domina los corners domina el juego, que la agresividad ayuda. Son afirmaciones intuitivas y muy repetidas, pero rara vez se contrastan con datos. Este trabajo busca ponerlas a prueba y medir cuáles de las estadísticas de un partido se relacionan realmente con el resultado, algo útil para distinguir los indicadores que informan sobre el rendimiento de aquellos que solo reflejan volumen de juego.

Para ello se utilizó la base pública de football-data.co.uk, que reúne los resultados de las cinco grandes ligas europeas (Premier League, La Liga, Serie A, Bundesliga y Ligue 1) entre las temporadas 2000/01 y 2024/25. El conjunto contiene 44.957 partidos, con goles, resultado final y, para cada equipo, tiros, tiros al arco, corners, faltas y tarjetas amarillas y rojas. Si bien la base es amplia, presenta una limitación que condiciona el alcance del análisis: no incluye la posesión del balón, una de las estadísticas más discutidas del fútbol, por lo que no puede evaluarse su relación con el resultado.

La pregunta que guía el trabajo es la siguiente: ¿qué estadísticas de un partido (tiros al arco, tiros fuera del arco, corners, faltas, tarjetas y jugar de local) se asocian más con la probabilidad de que un equipo gane? Para responderla se exploran los datos, se examina cómo cambió la ventaja de jugar de local a lo largo de los años y se ajusta un modelo de regresión logística que permite comparar el peso de cada estadística al mismo tiempo.

3. Datos y metodología

La base contiene 44.957 partidos y 23 columnas, donde cada fila es un partido. Incluye identificadores (temporada, liga, fecha y equipos), los goles al final de cada partido y al entretiempo, el resultado, y seis estadísticas de juego registradas para cada equipo: tiros, tiros al arco, corners, faltas, tarjetas amarillas y tarjetas rojas. La calidad de los datos se revisó con la exploración inicial: no hay filas duplicadas, pero entre el 12 % y el 15 % de las estadísticas de juego está sin registrar. Esos faltantes no son aleatorios, ya que corresponden a ligas y temporadas completas (La Liga, Ligue 1 y Serie A antes de 2005/06, y la Bundesliga en 2002/03).

Se aplicaron cuatro transformaciones. Primero, la fecha se convirtió a formato de fecha y se creó el año de inicio de cada temporada. Segundo, se conservaron solo los partidos con estadísticas completas (37.694, el 83,8 %) en lugar de imputar los faltantes, ya que estimar partidos enteros equivaldría a inventar datos; se eliminaron además 3 filas incoherentes (con más tiros al arco que tiros totales). Tercero, cada partido se desdobló en dos observaciones, una por equipo, para estudiar si *un equipo* gana o no, lo que dio 75.388 observaciones. Cuarto, se crearon variables

derivadas: los tiros fuera del arco (tiros menos tiros al arco) y, para cada estadística, la diferencia entre el equipo y su rival, ya que ganar depende de cuánto se supera al oponente y no del valor absoluto. La variable a explicar es la victoria, que vale 1 si el equipo ganó y 0 si empató o perdió (37,3 % de las observaciones).

Para medir el peso de cada estadística se ajustó una regresión logística, un modelo que estima la probabilidad de un resultado de dos categorías (ganar o no ganar) a partir de varias variables a la vez. Las variables se estandarizaron para poder compararlas entre sí, y se verificó que no estuvieran fuertemente correlacionadas entre ellas. El modelo se entrenó con el 80 % de los partidos y se evaluó con el 20 % restante, de modo que las dos observaciones de un mismo partido quedaran siempre del mismo lado, y se confirmó su estabilidad con una validación cruzada de cinco pliegues. El análisis se realizó en Python (Google Colab), con las librerías pandas, NumPy, SciPy y scikit-learn para los datos y el modelado, y Matplotlib y seaborn para los gráficos.

4. Resultados

4.1. La localía existe, pero se fue achicando. El primer hallazgo no tiene que ver con tiros ni con corners, sino con el lugar donde se juega. En las cinco ligas el resultado más frecuente es la victoria local, que oscila entre el 44,6 % (Serie A) y el 47,0 % (La Liga), por encima del 27–30 % de victorias visitantes (Figura 1). Sin embargo, esta ventaja no es constante: el porcentaje de victorias locales cayó del 47,9 % en 2000/01–2004/05 al 42,7 % en 2020/21–2024/25, con un mínimo de 39,9 % en 2020/21, temporada jugada en gran parte sin público por la pandemia, mientras que las victorias visitantes pasaron del 24 % a entre 30 % y 35 % (Figura 2). Los empates se mantuvieron estables.

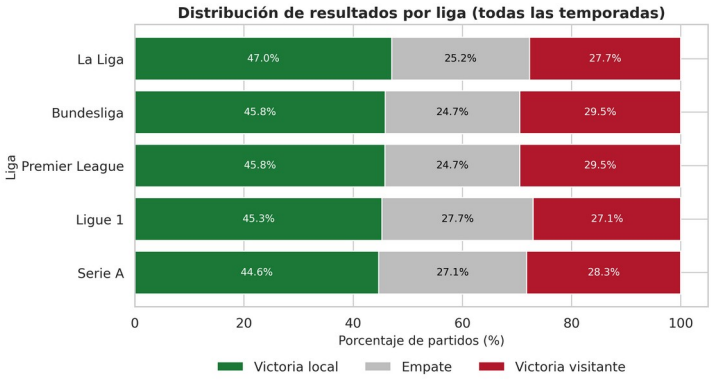


Figura 1. *Distribución de resultados por liga (todas las temporadas). Fuente: elaboración propia.*

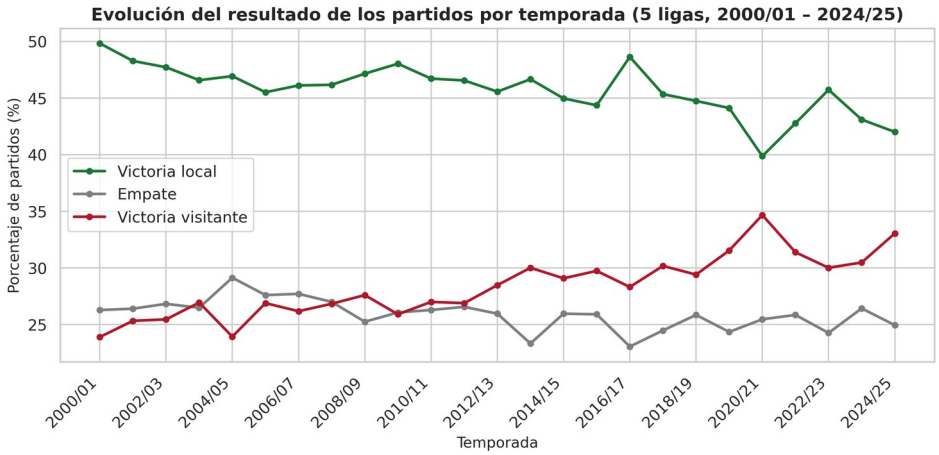


Figura 2. *Evolución del resultado de los partidos por temporada (5 ligas, 2000/01 – 2024/25). Fuente: elaboración propia.*

4.2. Ganar no es tirar más, sino tirar mejor. Al comparar las estadísticas de los equipos según su resultado, aparece una diferencia clara en una sola de ellas (Figura 3). Los equipos que ganan realizan en promedio 6,00 tiros al arco por partido, contra 4,33 de los que empatan y 3,70 de los que pierden. En cambio, la cantidad de tiros desviados es casi igual entre ganadores y perdedores (7,79 y 7,44), y los corners (5,19 y 4,92) y las faltas (13,57 y 13,87) prácticamente no cambian. Lo que distingue a quien gana es, por lo tanto, la calidad del tiro y no su volumen. Las tarjetas rojas también varían (0,06 por partido en victorias contra 0,16 en derrotas), aunque es probable que reflejen un partido que ya se estaba perdiendo y no una causa de la derrota.

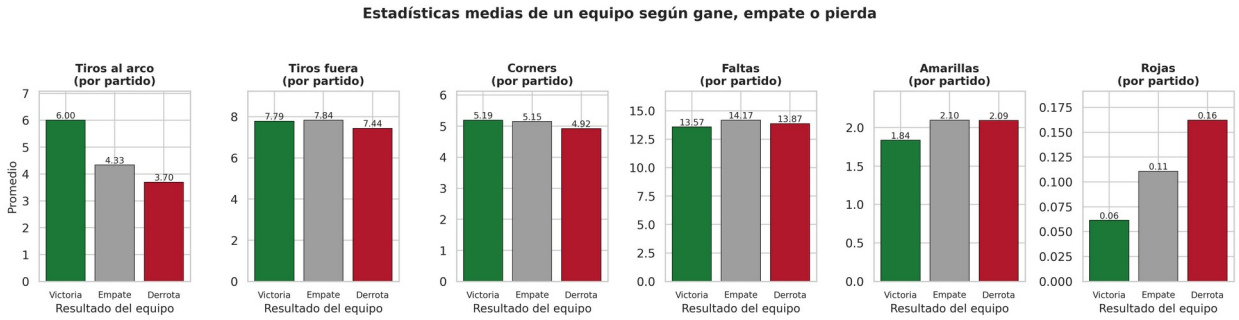


Figura 3. *Estadísticas medias de un equipo según gane, empate o pierda. Fuente: elaboración propia.*

4.3. De los partidos a las temporadas. Esta relación se sostiene a lo largo de una temporada completa. Al graficar, para 2.034 equipos-temporada, la diferencia media de tiros al arco con sus rivales contra los puntos obtenidos por partido, se observa una relación lineal positiva y fuerte (r = 0,85; Figura 4). Según la recta de ajuste, cada tiro al arco de ventaja por partido equivale a unos 0,22 puntos por partido: dos tiros de ventaja se traducen en alrededor de 17 puntos en una temporada de 38 fechas. La relación es similar en las cinco ligas.

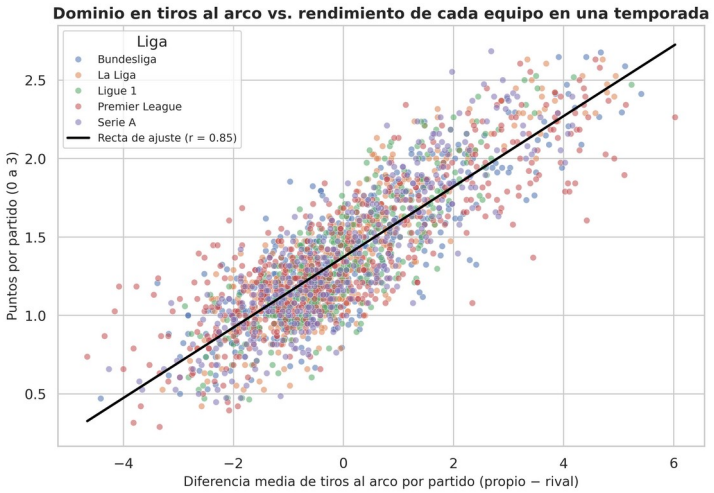


Figura 4. *Dominio en tiros al arco vs. rendimiento de cada equipo en una temporada. Fuente: elaboración propia.*

4.4. El peso de cada estadística en conjunto. Para medir el aporte de cada estadística controlando las demás, se ajustó la regresión logística. La Tabla 1 muestra cuánto cambia, en promedio, la probabilidad de ganar de un equipo cuando cada estadística varía una unidad respecto de su rival. Un equipo que iguala a su rival en tiros al arco gana el 33,5 % de las veces; con dos tiros de ventaja, el 50,1 %, y con cuatro, el 64,1 %. Jugar de local suma unos 8 puntos porcentuales aun con las mismas estadísticas, de modo que la localía no se explica solo porque el local tire más. Los corners, las tarjetas amarillas y los tiros desviados restan un poco una vez descontados los tiros al arco, y las faltas no tienen efecto relevante. El modelo clasifica correctamente el 74,5 % de los casos, frente al 62,6 % de un modelo que predijera siempre "no ganar", y su desempeño se mantuvo estable en la validación cruzada.

Tabla 1. *Efecto estimado de cada estadística sobre la probabilidad de ganar.*

Estadística	Cambio considerado	Efecto sobre la probabilidad de ganar
Tiros al arco	+1 respecto del rival	+6,2 puntos porcentuales
Jugar de local	Local en lugar de visitante	+8,3 puntos porcentuales
Tarjetas rojas	+1 respecto del rival	−9,8 puntos porcentuales
Corners	+1 respecto del rival	−1,6 puntos porcentuales
Tarjetas amarillas	+1 respecto del rival	−1,3 puntos porcentuales
Tiros fuera del arco	+1 respecto del rival	−0,7 puntos porcentuales
Faltas	+1 respecto del rival	+0,1 puntos porcentuales

Nota: efecto promedio sobre el conjunto de prueba, con el resto de las estadísticas sin cambios. Fuente: elaboración propia.

5. Conclusiones

El trabajo partió de una idea muy extendida, que gana el que más tira, y los datos la matizan: lo que distingue a los ganadores es la calidad del tiro y no su cantidad. Los equipos que ganan tiran al arco bastante más que los que pierden (6,00 contra 3,70 por partido) pero no tiran mucho más en total, y cada tiro al arco de ventaja sobre el rival suma unos 6 puntos porcentuales a la probabilidad de ganar. La relación se sostiene a lo largo de las temporadas ($r = 0,85$ entre la ventaja en tiros al arco y los puntos por partido). La localía es el segundo factor: aun con las mismas estadísticas, jugar de local suma unos 8 puntos porcentuales, aunque la proporción de victorias locales bajó del 47,9 % al 42,7 % en 25 años. Corners, faltas y tarjetas amarillas aportan poco o nada. El modelo clasifica correctamente el 74,5 % de los casos.

Estos resultados tienen límites. El principal es la ausencia de la **posesión del balón**, una de las estadísticas más discutidas del fútbol, que la base no registra y que por eso no pudo evaluarse; tampoco hay goles esperados, pases ni duelos. Además, el 16 % de los partidos carece de estadísticas, de modo que las conclusiones se apoyan sobre todo en las temporadas desde 2005/06. Los resultados describen asociaciones y no causas: las estadísticas corresponden al partido terminado y reflejan su desarrollo (quien va perdiendo suele presionar y quien va ganando, replegarse), lo que podría explicar, por ejemplo, el signo de las tarjetas rojas y los corners. Los tiros al arco, además, están muy cerca de los goles, por lo que parte de su peso es casi mecánico. Tampoco se controló la calidad de los equipos, y la categoría "no ganar" agrupa empates y derrotas.

Como extensiones, la más natural es incorporar la posesión y otras métricas desde fuentes que las registren, para comprobar si agregan información más allá de los tiros al arco. También sería

valioso controlar por la jerarquía de cada equipo, separar el análisis por liga y época, y modelar las tres categorías (victoria, empate y derrota) para estudiar qué distingue al empate.

6. Reflexión metodológica

Se utilizó inteligencia artificial como apoyo en la programación del análisis y en la redacción del informe. Al revisar el notebook inicial se detectó que había corrido con datos simulados y no con la base real, por lo que el análisis se rehízo sobre el CSV de football-data.co.uk. También se descartó incorporar datos de posesión generados por IA, ya que no provenían de partidos reales, y se prefirió declarar su ausencia como limitación. El grupo revisó los resultados, eligió los gráficos del informe y decidió simplificar el modelado, dejando solo la regresión logística, para poder explicar cada resultado. Como aprendizajes, el trabajo permitió comprender que en el fútbol importa más la calidad del tiro que su cantidad y que la ventaja de localía se fue reduciendo con los años. En lo técnico, mostró la importancia de limpiar y transformar los datos antes de modelar, y de verificar lo que produce una IA en lugar de aceptarlo sin más.